

Classificação de Imagens no Conjunto de Dados MPEG7

1st Marcus Vinicius Diniz dos Reis
Universidade Federal de Viçosa - UFV
Rio Paranaíba, Brasil
marcus.v.reis@ufv.br

2nd Brenno Alves Silva
Universidade Federal de Viçosa - UFV
Rio Paranaíba, Brasil
brenno.alves@ufv.br

Abstract—This project aimed to develop an automated approach for shape classification in images. The methodology involved segmenting the dataset images to isolate shapes, extracting morphological features such as area, perimeter, and circularity, and selecting the most relevant features for classification. The dataset was split into training, validation, and testing sets, ensuring reproducibility with a predefined seed. Data normalization was applied to standardize feature scales. Two classifiers were implemented and evaluated: k-Nearest Neighbors (k-NN) and Support Vector Classifier (SVC). The performance of both models was assessed using the test set, with metrics such as accuracy, precision, recall, and F1-score. The results highlighted the effectiveness of the SVC in handling complex data patterns, while k-NN provided consistent performance under specific conditions. The findings demonstrate the robustness of the proposed pipeline and suggest areas for further improvement.

Index Terms—Shape classification, image segmentation, morphological feature extraction, k-Nearest Neighbors (k-NN), Support Vector Classifier (SVC), data normalization, performance evaluation, machine learning, classification metrics.

I. INTRODUCTION

O objetivo do projeto foi desenvolver uma abordagem automatizada para classificação de formas em imagens. As etapas realizadas incluíram segmentação das formas, extração de características, divisão dos dados, normalização, treinamento e avaliação de classificadores. O foco foi otimizar o desempenho do modelo, utilizando métricas clássicas como acurácia, precisão, recall e F1-score para análise.

II. METODOLOGIA

A. Segmentação das Imagens

Inicialmente, as imagens foram segmentadas para identificar e isolar as formas presentes. Técnicas de processamento de imagens, como limiarização e detecção de contornos, foram aplicadas para garantir uma segmentação precisa.

B. Extração de Características Morfológicas

Foram computadas características morfológicas, como área, perímetro e circularidade. A seleção das características relevantes para classificação foi baseada em sua capacidade de discriminação entre diferentes classes de formas [1] a qual usamos de suporte uma engenharia de características. E a as características escolhidas foram a área e a solidez.

C. Divisão do Conjunto de Dados

O dataset foi dividido em conjuntos de treino de 70%, validação e teste 30%. O tamanho do conjunto de validação foi ajustado experimentalmente, enquanto a seed 42 foi utilizada para garantir reprodutibilidade.

D. Normalização dos Dados

Antes do treinamento, as características extraídas foram normalizadas para garantir que todas estivessem na mesma escala, evitando vieses durante o aprendizado do modelo.

E. Treinamento e Teste do Classificador

Foram implementados dois classificadores: *k-Nearest Neighbors* (k-NN) e *Support Vector Classifier* (SVC). O SVC foi escolhido devido à sua capacidade de separar classes utilizando margens máximas em espaços de alta dimensionalidade, sendo eficaz para dados com padrões complexos. A otimização de hiperparâmetros foi realizada para ambos os modelos, buscando o melhor desempenho no conjunto de validação.

III. RESULTADOS E DISCUSSÃO

A avaliação foi conduzida no conjunto de teste. As principais métricas foram obtidas através da matriz de confusão e do relatório de classificação e a avaliação do desempenho dos modelos foi feita utilizando as métricas padrão de aprendizado de máquina, como precisão, recall e F1-score, conforme descrito por Powers [2]. A tabela a seguir resume os resultados:

TABLE I
DESEMPENHO DOS CLASSIFICADORES

Classificador	Acurácia (%)	Precisão (%)	Recall (%)	F1-score (%)
k-NN	81	82	81	81
SVC	70	70	70	70

O k-NN apresentou uma acurácia de 81%, destacando-se com valores elevados para métricas de precisão, recall e F1-score. A classe bell teve o melhor desempenho individual, com um F1-score de 91%, enquanto a classe bird apresentou maior dificuldade, refletindo um recall de 70%.

Por outro lado, o SVC obteve uma acurácia de 70%, com desempenho mais equilibrado entre as classes. No entanto, a classe beetle foi a mais desafiadora, com F1-score de apenas

47%, indicando limitações na separação das formas mais complexas.

Esses resultados sugerem que o k-NN foi mais eficaz para esse conjunto de dados, possivelmente devido à simplicidade e à relação intrínseca entre as características extraídas. O SVC, embora menos performático, pode ser otimizado futuramente por meio de ajustes nos hiperparâmetros ou no conjunto de características utilizadas.

IV. CONCLUSÃO

O estudo comparou os classificadores k-NN e SVC para a classificação de formas em imagens. O k-NN obteve melhor desempenho, com acurácia de 81%, destacando-se em formas simples, mas apresentando desafios em classes mais complexas. O SVC, com acurácia de 70%, teve dificuldades, especialmente com a classe beetle. Esses resultados sugerem que, enquanto o k-NN foi mais eficaz neste cenário, o SVC pode ser melhorado com ajustes em hiperparâmetros ou técnicas adicionais. Futuros trabalhos podem explorar outras abordagens, como redes neurais, para melhorar a precisão do modelo.

REFERENCES

- [1] R. C. Gonzalez and R. E. Woods, *Digital Image Processing*, 3rd ed., Prentice Hall, 2008.
- [2] D. M. W. Powers, "Evaluation: From Precision, Recall and F-Score to ROC, Informedness, Markedness and Correlation," *Journal of Machine Learning Technologies*, vol. 2, no. 1, pp. 37-63, 2011.